



סדנת Machine Learning

מפגש חשיפה

חלק מהশকפim נלקחו מהספר:

"An Introduction to Statistical Learning"

© אברהם עיני



כיום, אנו אוספים מידע מהמון מקורות שונים - מערכות, חישנים, מכשורי מדידה, לוגים, קבצים שונים ועוד.

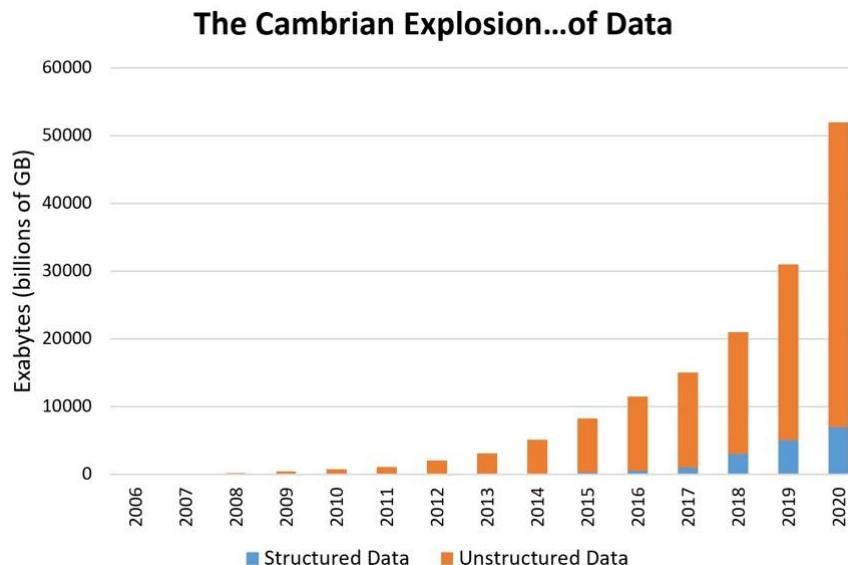


4 V's:

- **Volume** (נפח)
- **Velocity** (מהירות)
- **Variety** (מגוון)
- **Veracity** (אמינות)

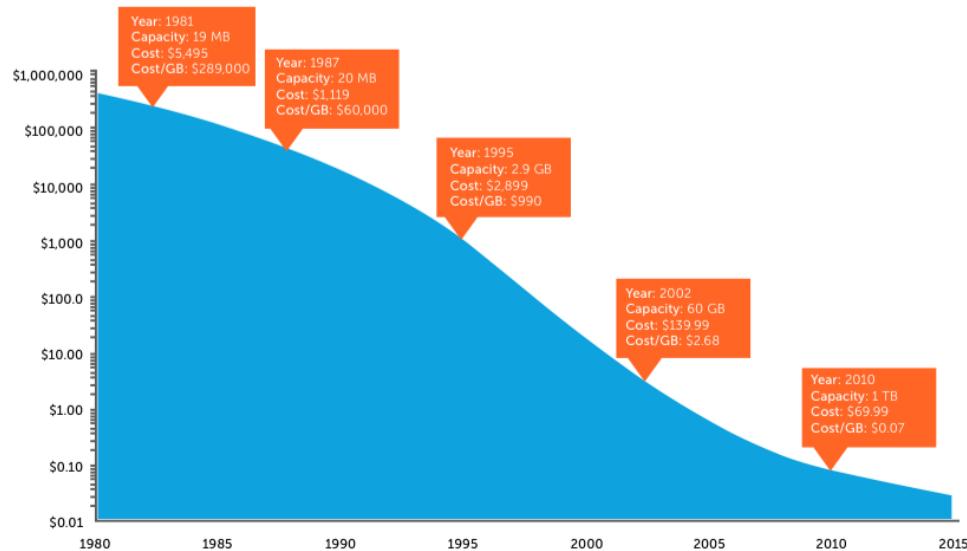


קצב גידילת המידע עולה בצורה משמעותית ונדרשים לפתרונוות יותר יצירתיים בתחום האחסון וזמינות המידע.



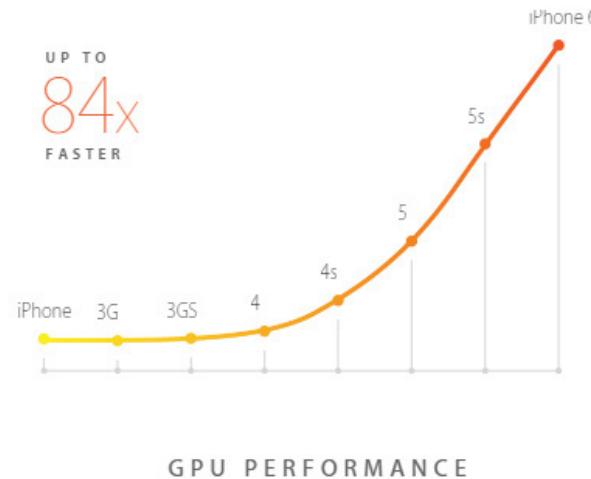
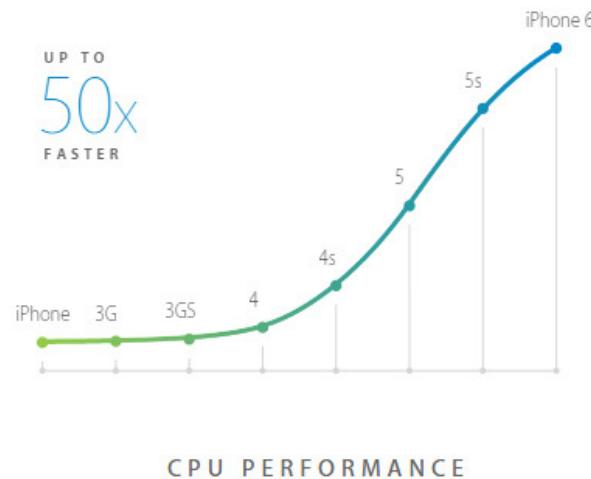


מצד שני, עלות האחסון הולכת וירדת מה שמאפשר לנו לאחסן כמויות גדולות של מידע, דבר שב吃过 לא יכולנו לבצע.



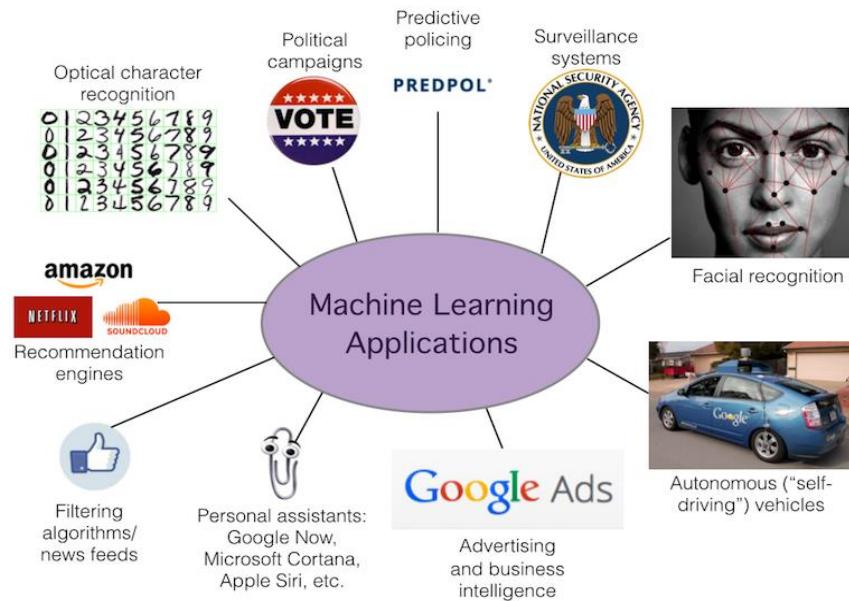


בנוסף, ביצועי החומרה והיעבוד של ציוד המחשב הולכים ומשתפרים בצורה משמעותית.

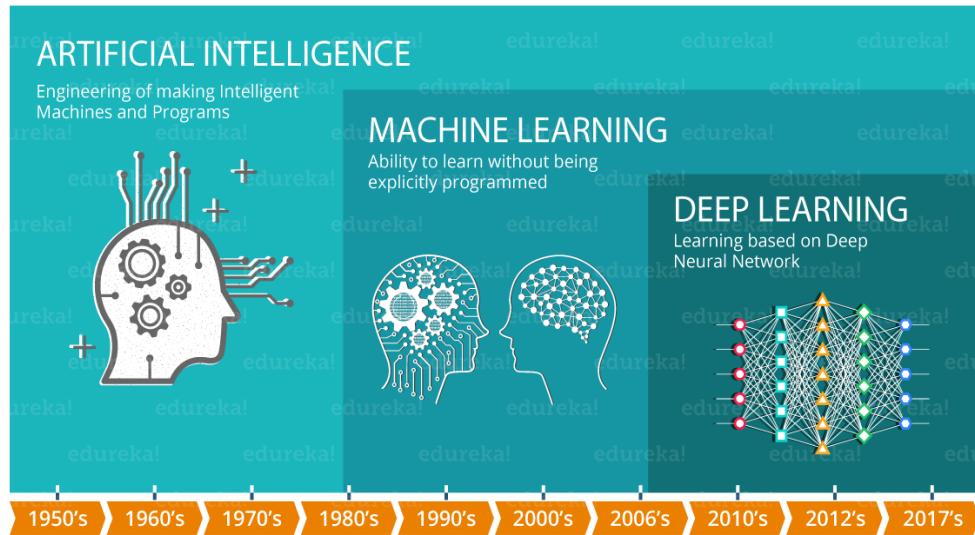




עם האתגר הכרוך באחסון ועיבוד המידע מבינה טכנית, ישנה הזדמנות לשימוש בكمיות המידע העצומות, באמצעות כוח החישוב הגדל, ולהפיק תובנות במגוון תחומים (שאות חלקם נזכיר המשך) כגון: אחזור מידע, עיבוד שפה טבעית, עיבוד תמונה, חיזוי, מערכות המלצה ועוד.



מהי למידה חישובית?

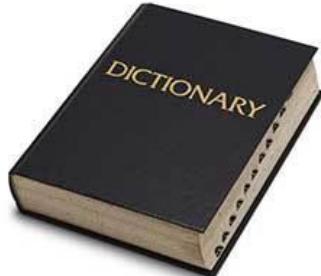


- **הגדרה ראשונית:** "הkninit יכולת שיפור אוטומטי של ביצועי מחשב" במשימות מורכבות

- **מינוח בעברית:**

- **למידת מכונה / למידה ממוכנת**
- **למידה ממוחשבת / למידה חישובית**

מהי למידה חישובית?



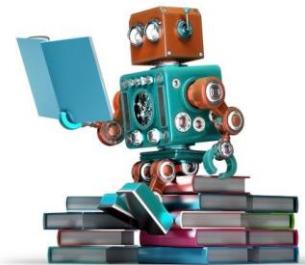
- **הגדרה מילונית:** "רכישת ידע, הבנה או יכולת באמצעות ניסיון או לימוד
- **הגדרה אופרטיבית יותר (לפי H.Simon, 1983):**
 - **מערכת לומדת:** מערכת אשר משפרת את ביצועיה ביצועי משימה נתונה ככל שהיא מבצעת משימה זו

הגדרה الأخيرة מתאימה לסוג מסוים של למידה – למידה תוך כדי עשייה.
בсадנה, אנו נתמקד בעיקר בלמידה באמצעות דוגמאות.

למידה חישובית או אלגוריתם קבוע

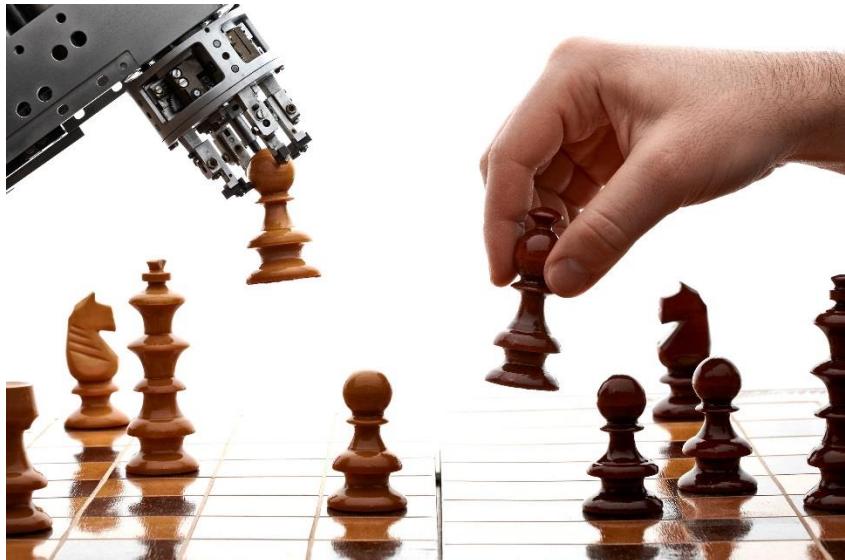


- אלגוריתם קבוע-
 - כל פרטי הפתרון נקבעים ומקודדים מראש ביד' המפתח
 - ביצוע המערכת קבועים



- מערכת לומדי-
 - האלגוריתם כולל פרמטרים אשר **מתכוונים** בטהיליך הלמידה
 - ביצועי המערכת משתפרים במהלך הלמידה

שימושים ללמידה חישובית



א. Games AI:

שימוש בסוכן למטרת לימוד וחיזוי פעולות ותגובה במערכות משחק שונות תוך כדי לימוד אסטרטגיה אופטימלית.

דוגמאות שימוש:

- משחקי סוכן בודד/רובה
- משחקי עולם דטרמיניסטי/סתוכסטי
- משחקים בעלי עולם סופי/לא סופי

חברת Google DeepMind מלמדת סוכן לשחק במשחק Atari

שימושים ללמידה חישובית



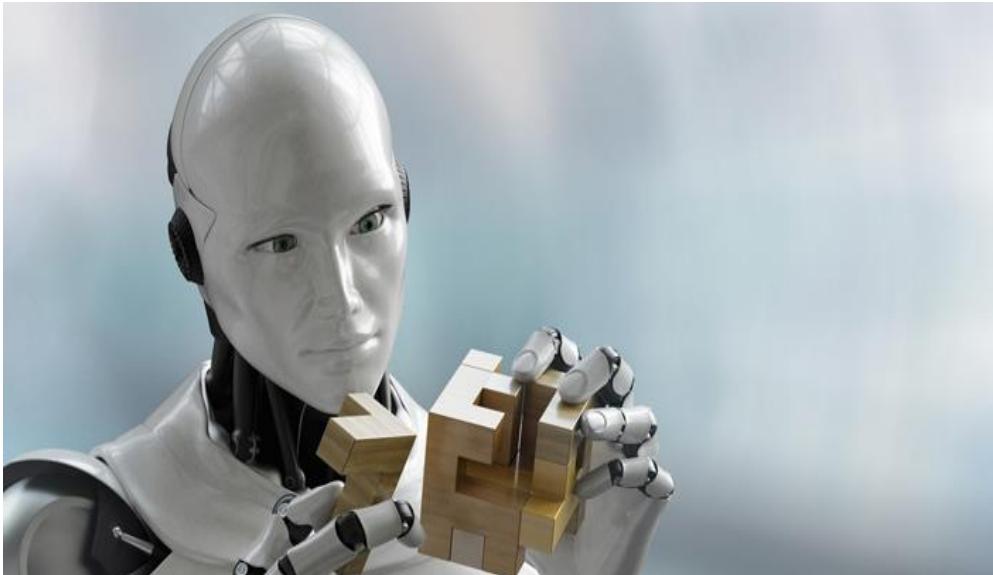
ב. Planning:

שימוש בסוקן למטרות גילוי/תחקור ולמידת פעולהTAGOVERNMENT של מצבים השונים.

דוגמאות שימוש:

- iRobot
- מכוניות אוטונומיות
- תכנון מסלול ועוד.

[רובוט של חברת Boston Dynamics](#)



שימושים ללמידה חישובית



ג. מערכת המלצה:

מערכת המסוגלת לזהות קשרים ודמיון בין ישויות שונות במערכת ולהציע שירותים או מוצרים שונים לשימוש בהתאם.

דוגמאות שימוש:

Amazon •

YouTube •

Lifestyle •

מערכת ההמלצה של Amazon



The New York Times

Bloomberg

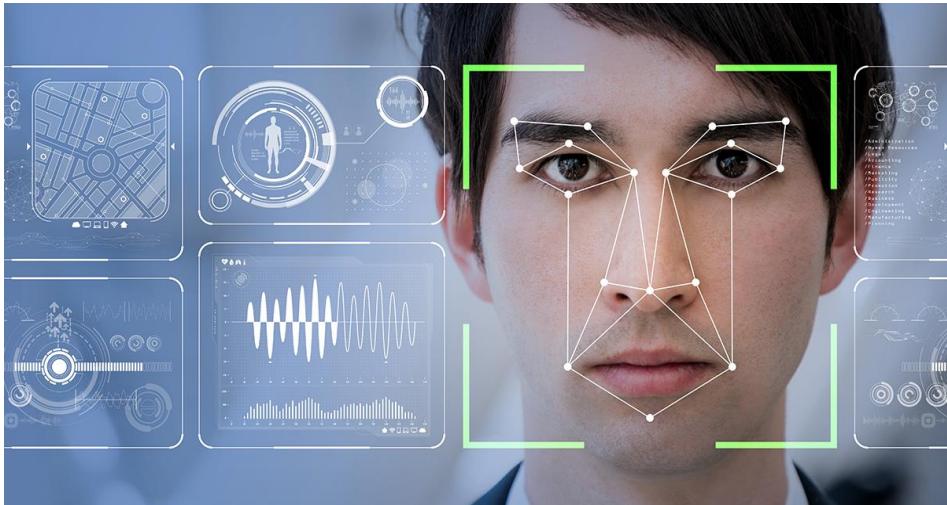
שימושים ללמידה חישובית



ד. עיבוד תמונה:

תחום העוסק בחידוד וריטוש תמונות, גילוי תנועה, זיהוי פנים והבעות פנים, דחיסת מידע ועוד.

דוגמאות שימוש:



- זיהוי כתף יד
- OCR
- מכוניות אוטונומיות ובטחה.

סרטון של חברת Nvidia "מייצרת" סלבס
חדשים

שימושים ללמידה חישובית



הביצוע ניתוחים ותחזיות:

שימוש נתונים קיימים לצורך יצירת חיזויים עתידיים (prediction) והבנת השפעות של גורמים שונים על ערכיהם אלו (inference)

דוגמאות שימוש:

- חיזוי מזג האוויר
- מנויות בורסה
- מחקרים רפואיים
- ניתוח מוצרים

שימושים ללמידה חישובית



ו. עיבוד שפה טבעיות:

תחום העוסק בניתוח ומחקר של בעיות הקשורות בתחום השפה על מנת לגרום למחשב "להבין" דברים שנאמרים/כתבם בשפה אנושית.

דוגמאות שימוש:

- תרגום שפות
- זיהוי קול
- סיכון מסמכים, סיוג טקסט, אחזור מידע ועוד.

[Google מציגה עזרת אישית](#)



שימושים ללמידה חישובית



2. הגנת סייבר:

שימוש בניתוח של נתונים רשות, תעבורת
וקבצים בכדי למנוע ולהגן מפני פריצה לרשות.

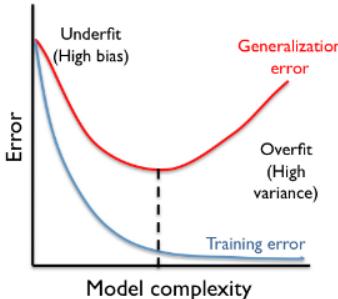
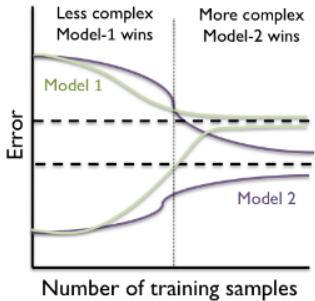


דוגמאות שימוש:

- **זיהוי קבצים חשודים**
- **Pattern Recognition**
- **מציאת אונומליות**
- **אפיון תוקפים ועוד**



Course Descriptions





Blend it all together look up

In the last few exercises you've learned everything there is to know about heights and weights of baseball players. Now it's time to dive into another sport: soccer!

You've contacted FIFA for some data and they handed you two lists. The lists are the following: `positions = ['GK', 'M', 'A', 'D', ...]` heights = [191, 184, 185, 180, ...]. Each element in the lists corresponds to a player. The first list, `positions`, contains strings representing each player's position. The possible positions are: "GK" (goalkeeper), "M" (midfielder), "A" (attack) and "D" (defender). The second list, `heights`, contains integers representing the height of the player in cm. The first player in the lists is a goalkeeper and is pretty tall (191 cm).

You're fairly confident that the median height of goalkeepers is higher than that of other players on the soccer field. Some of your friends don't believe you, so you are determined to show them using the data you received from FIFA and your newly acquired Python skills.

Instructions

```
script.py
1 # heights and positions are available as lists
2
3 # Import numpy
4 import numpy as np
5
6 # Convert positions and heights to numpy arrays: np_positions, np_heights
7
8
9
10 # Heights of the goalkeepers: gk_heights
11
12 # Heights of the other players: other_heights
13
14
15
```

Submit Answer

IPython Shell Slides

In [1]:

- **חלק תיאורתי-פגישה** בת כהען
 - אחת לחודש בה נעבור על נושאים
 - בצורה יותר תיאורטיבית-הבנייהית
 - תוך הצגת אלגוריתמים שונים
 - ודוגמאות שימוש בмагון עלילות.
 - נדרש רקע מתמטי ברמה בסיסית
 - ורצוי גם בסטטיסטיקה (לא חובה)

- **חלק מעשי** - הפניה לחומרים שונים (אטרים, ווידאו, מצגות) שעוסקים בנושא מן המבט המעשי/תכניות תוך עבודה עצמית.



Course Descriptions



מטרת הסדנה:

- הגברת המודעות לתחום הלמידה החישובית והיתרונות ביכולות המצויות בתחום זה
- חשיפה למגוון רחב של שימושים מעשיים שונים מתחומי עיסוק שונים
- היכרות עם אלגוריתמים בסיסיים ותקדמים
- פיתוח יכולות כתיבת ואפויון מודלים והתאמתם למקרים מעשיים



Course Descriptions



תוכן הסדנה:

- הקדמה
- רגרסיה לינארית
- סיווג ורגרסיה לוגיסטיבית
- שיטות דגימה ובחירה מודל
- עצי החלטה
- קיבוץ (Clustering)
- למידה عمוקה (Deep Learning) (אם תהיה אפשרות)
- נושאים מתקדמים (אם תהיה אפשרות)

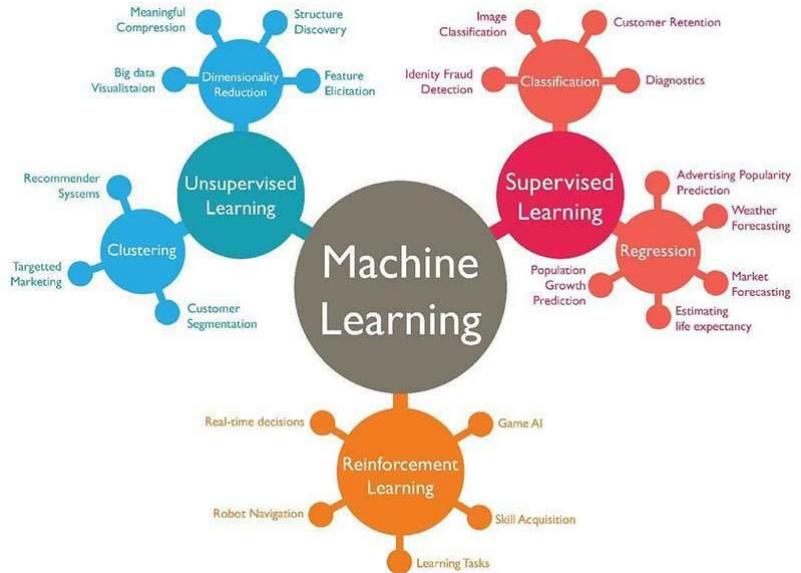


קיימים 3 סוגי של למידה:

1. למידה מונחית (Supervised Learning)

2. למידה לא מונחית (Unsupervised Learning)

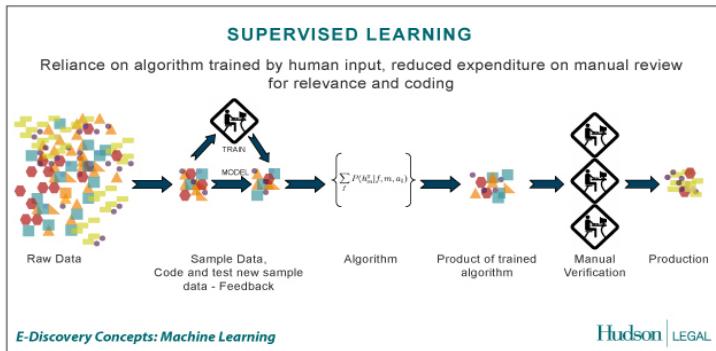
3. למידה מחיזוקים (Reinforcement Learning)



למידה מונחתית (Supervised Learning)



למידה מונחתית היא למידה בה המידע שיש לנו מורכב משני חלקים:



- א. פרמטרים : גיל, מין , השכלה , ותק וכו'.
 - ב. תיאוג/ערוך: הכנסה, ציון פסיקומטרי, ממצאי בדיקה רפואי וכו'.
- לכל דוגמה (נניח אדם) ישנו פרמטרים ותיאוג של>User
- אנו ננסה באמצעות מודל לחזות את>User התיאוג בהינתן הפרמטרים.
- או בכתיבה המתמטית:

- פרמטרים: x
- תיאוג: y

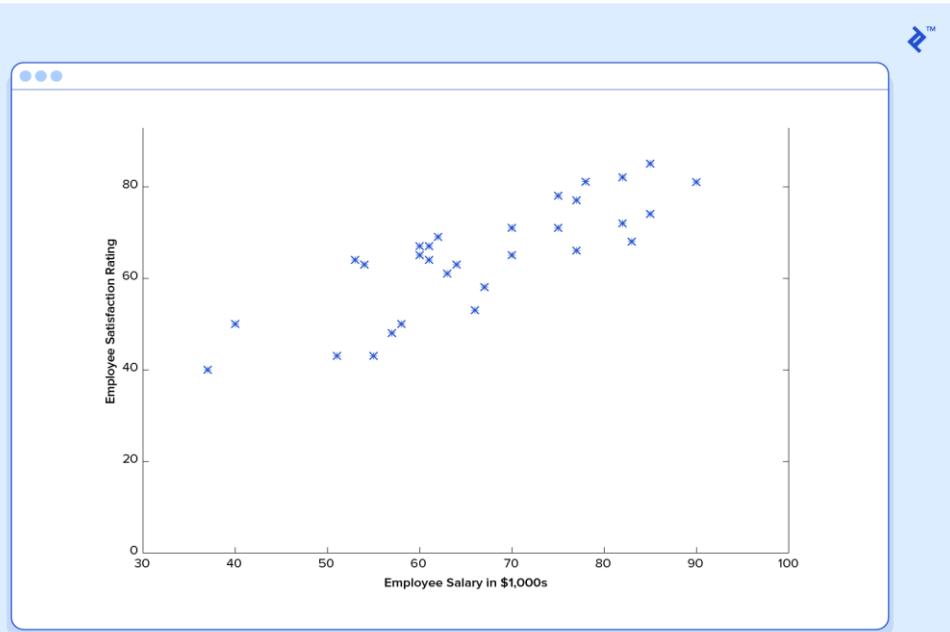
המודל אותו אנו מנסים ללמוד: $\hat{y} = \hat{f}(x)$ כאשר, \hat{y} הוא התיאוג המתקבל מהמודל שלנו ו- $\hat{f}(x)$ פונקציה המקבלת את הפרמטרים ומיצרת>User ערך (לדוגמא: x) $\hat{f}(x) = b_0 + b_1 x$.

המטרה: לחזות \hat{y} כך שהיא "הכי קרוב" ל- y האמתי.

למידה מונחתית (Supervised Learning)



דוגמא:



נניח ובידינו נמצאים הנתונים הבאים על שביעות רצון העובדים (בסקללה של 0-100) ורמת השכר שלהם, כמו בגרף הבא:

אנו מעוניינים לחזות בהינתן רמת השכר את שביעות רצון העובד.

ראשית, ניתן לשים לב שהدادטא מעט רועש ולא אחיד, ועם זאת אנו מסוגלים לראות איזשהו קו מתנה שמראה כי ככל שהשכר עולה רמת שביעות הרצון עולה.

למידה מוחשית (Supervised Learning)



דוגמאות:

לאחר שהבנו כיצד המידע "מתנהג" علينا לבנות מודל שיתאר אותו. בהתאם למודל שהציגו מוקדם ניצג את המודל בצורה הבאה : $x = \theta_0 + \theta_1 h(x)$

א- שכר העובד

θ - משתנה חופשי (שלוט על ה"רמה ההתחלתית של שביעות הרצון – חותך לציר ה-

θ_1 - מקדם של משתנה השכר (בעצם כמה משתנה השכר משפיע על שביעות הרצון)

$h(x)$ - ערך שביועת הרצון החזוי (ניתן להתייחס אליו כ- \hat{y})

למידה מונחתית (Supervised Learning)



דוגמא:

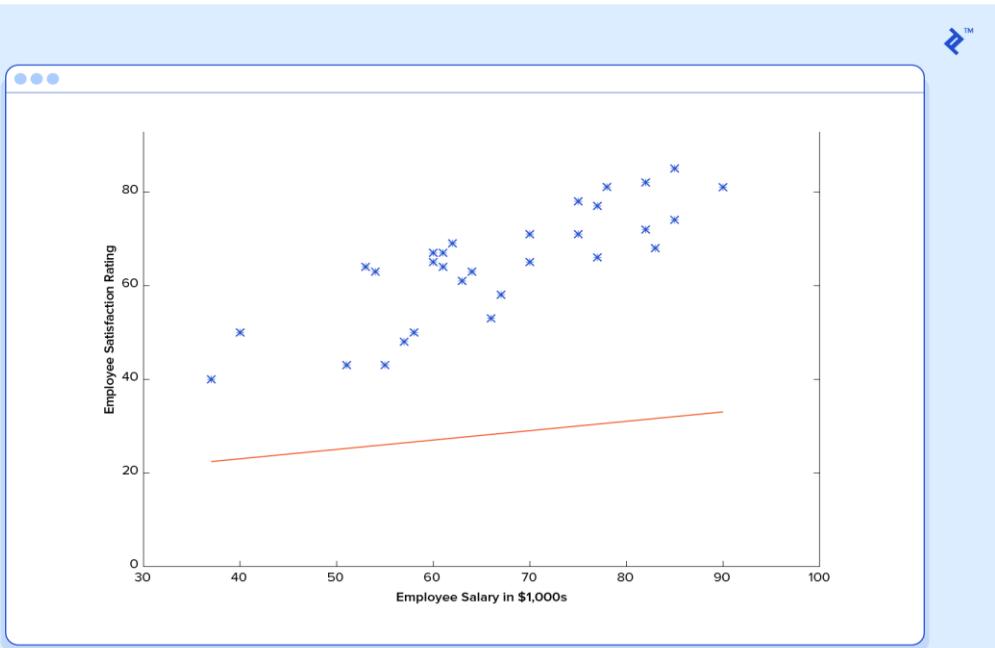
שלב האתחול:

натחל את המודל בצורה בסיסית עם ערכים
של:

$$\theta_1 = 0.2 \text{ ו } \theta_0 = 12$$

ונקבל: $.h(x) = 12 + 0.2x$

ניצג את המודל שקיבלנו בצורה גרפית
ונקבל:



למידה מונחתית (Supervised Learning)

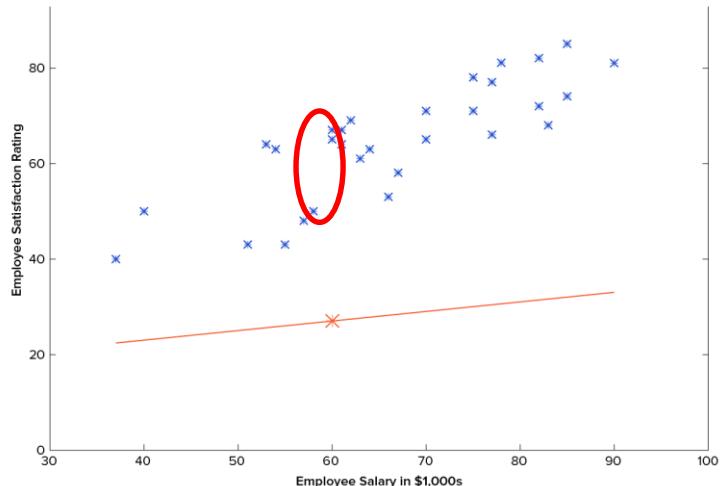


דוגמא:

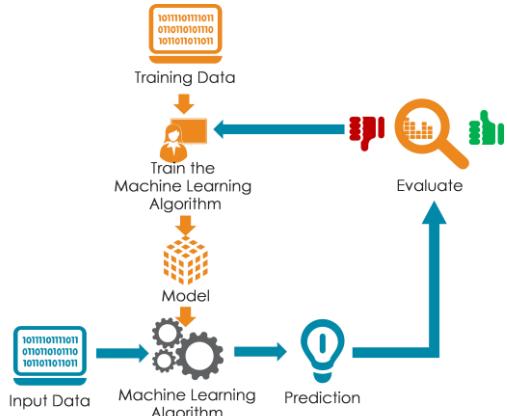
אם נבקש מהמודל לבצע פרדיקציה (תחזית) לרמת שביעות הרצון של עובד ששכרו הוא \$60k נקבל את התוצאה הבאה:

ניתן לומר בבירור שהמודל לא קרוב לתוצאה האמיתית (27 חזו מול 60-50).

מה עושים כדי לשפר את המודל? נאמן אותו!



למידה מונחתית (Supervised Learning)



דוגמא:

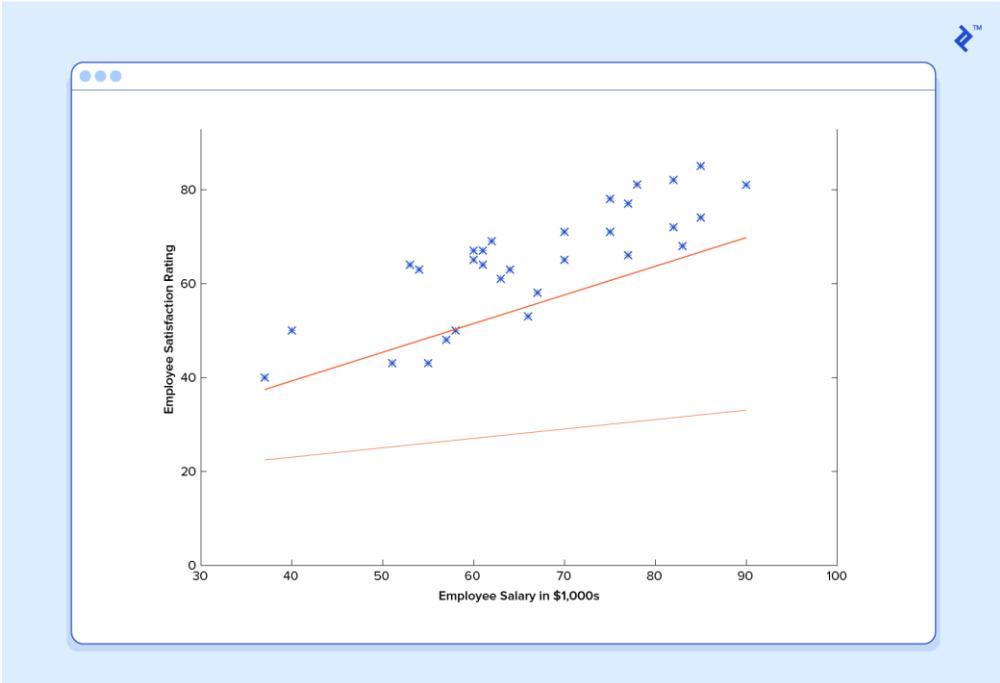
שלב האימון:

- נרצה לראות כמה אנו רוחקים מהתוצאות האמיתיות ולתקן בהתאם. לצורך כך:
1. געבור על כל הדגימות שברשותנו מمدגם האימון.
 2. מבצע תחזית עבור כל אחד ונמדד את השגיאה.
 3. נסכום את כל השגיאות ונמצא את השגיאה הממוצעת
 4. נבדוק (באמצעות גזירה – יוסבר לעומק בהרצאות הבאות) כמה עליינו לשנות כל משתנה במודול כך שימזער את השגיאה
 5. נחסיר/נוסיף לכל משתנה בהתאם לתוצאות שקיבלנו
 6. נחזיר לשלב הראשון ↑

למידה מונחתית (Supervised Learning)



דוגמא:



לאחר שביצענו סבב אימון אחד. קיבלנו שעבור
ערבים של $\theta_0 = 13.12$ ו- $\theta_1 = 0.61$, המודל
יריה יותר קרוב לתוצאות האמת. נכתוב את
המודל החדש:

$$h(x) = 13.12 + 0.61x$$

ניצג את המודל שקיבלנו בצורה גרפית ונקבל:

ניתן לראות שההתוצאות כבר סבירות.

למידה מונחתית (Supervised Learning)

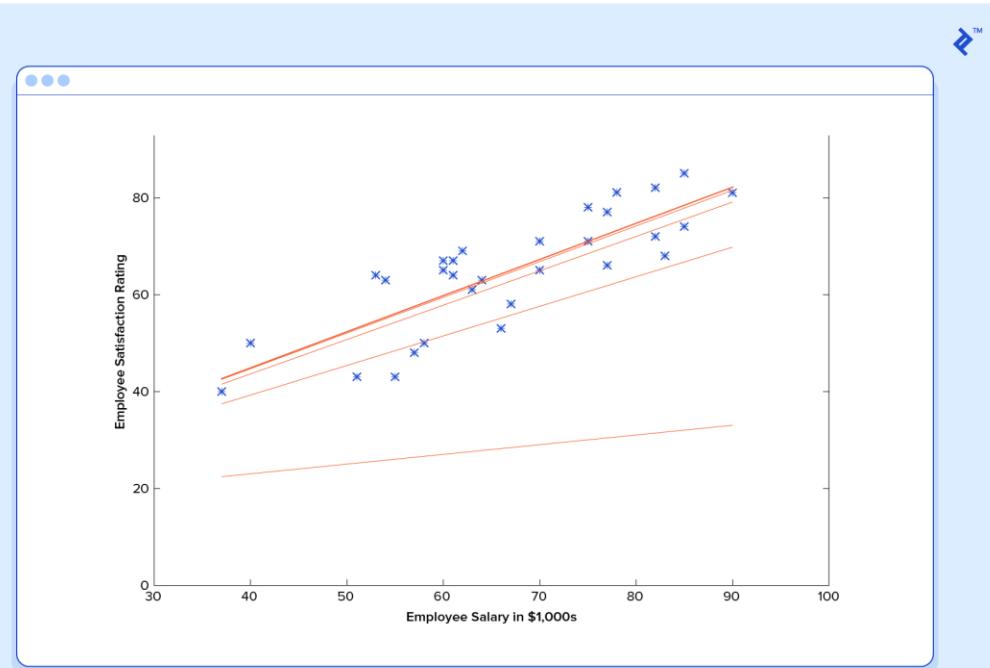


דוגמא:

אם נחזור על תהליך האימון המון פעמיים
(נניח 1500 איטרציות) נקבל את המודל
הבא:

$$h(x) = 15.54 + 0.75x$$

ניצג את המודל שקיבלנו בצורה גרפית
ונקבל:



וכשיו זה כבר נראה מעולה.
מה יקרה אם נחזור עוד פעם על תהליך
האימון?

למידה מונחתית (Supervised Learning)



Prediction vs Inference

ישנן שתי סיבות מרכזיות למוטיבציה למציאת \hat{y} : תחזית והסעה.

המודל האמיתי ממנו מגיעים הנתונים הוא: $\epsilon + Y = f(X)$,

כאשר Y -התיאוג, (X) -פונקציה על הפרמטרים ו- ϵ משתנה מקרי של השגיאה (בעל ממוצע 0)



תחזית

המודל שאנו מנסים לבנות עבור הנתונים הוא: $\hat{Y} = \hat{f}(x)$

כאשר \hat{Y} התיאוג המוערך ו- $\hat{f}(x)$ -הערכה לפונקציה המקורית (מכיוון והוא בעל תוחלת 0 הוא אינו מחושב במודול)

למידה מונחת (Supervised Learning)



מציר דוגמא להמחשה:

לפגיעה משמעותית במקרה של נטילת תרופה מסוימת.

נרצה כמובן, לחזות את הערך של \bar{Y} ובכך להימנע מלהתדרדר לחולה הנמצאת בסיכון.

aicot ha'chiizi shel Z talioha b'shi gorimim:

.Irreducible Error-I Reducible Error

בדרך כלל, $\hat{f}(x)$ לא תייצג במדויק מושלמת את $f(x)$, אך זהה שגיאה הניתנת למזעור (ע"י טכניקות סטטיסטיות שונות) וזויה ה- **Reducible Error**.

למידה מוחשית (Supervised Learning)



מצד שני, אפילו אם $(x) = \hat{f}(x) = \hat{Y}$ ככלומר, מצאנו את הפונקציה האמיתית, עדין תישאר לנו שגיאת שהיא תלולה ב- ϵ .

בצמצום, במשתנה הזיה כלולים כל המשתנים שחסרים לנו להסביר את המודל, והשוניות שאין מוסברות.

נוכל ליעזג זאת בצורה הבאה:

$$E(Y - \hat{Y})^2 = E[f(x) + \epsilon - \hat{f}(x)]^2 = [f(x) - \hat{f}(x)]^2 + \text{Var}(\epsilon)$$

נחוות למקורה שלמו:

השפעת התרופה על המטופל יכולה להיגרם ממשתנים שאינם נמדדים- היסטוריה ניתוחים, זיהומיים שונים, מצב נפשי וכו', כמו כן השפעה יכולה לשנתנות ביום מסוים ולפי איקות התרופה הספרטיפית.

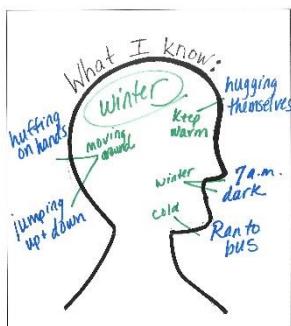
למידה מונחתית (Supervised Learning)



Prediction vs Inference contd

הסקה

לעתים אנו מעוניינים להבין את הדרך בה Y מושפע כאשר X_1, X_2, \dots, X_p משתנים. במקרה זה אנו עדין מעוניינים למצוא את $(x) \hat{f}$ אבל המטריה איננה בהכרח לבצע תחזיות. אנו רוצים להבין כיצד Y משתנה כפונקציה של X_1, X_2, \dots, X_p . במקרה זה נהיה מעוניינים לענות על השאלות הבאות למשל:



- אילו משתנים קשורים לשינוי בתוצאה?
- מהו כיוון הקשר בין המשתנה לערך החזו? האם הערך הזה תלוי במשתנים נוספים?
- האם הקשר בין המשתנים הוא לינארי או מקטיים קשר מסווג שונה?

למידה מונחתית (Supervised Learning)



Prediction vs Inference contd

דוגמאות :

- חברות פרסום- מעוניינת לחזות משתמשים שייענו בחוב למילימ שישלחו אליהם – **תחזית**
- חברת מכירות- מעוניינת להבין כיצד שינוי של מחיר המוצר ישפיע על היקף המכירות שלו – **הסקה**
- חברת נדל"ן – מעוניינת להבין מהי רמת ההשפעה של קרבה למרכז מסחרי על מחירי בתים, כמו כן, מעוניינת לחזות מחירי בתים לפי הפרמטרים השונים – **הסקה ותחזית**

מדוע זה חשוב לנו?

ישנם מודלים שונים המשמשים לצרכים שונים ועלינו לבחור את המודל המתאים לצורך הספציפי שלנו.

למידה מונחתית (Supervised Learning)



Regression VS Classification

משתנים יכולים להופיע בשתי צורות בסיסיות: משתנים כמותיים (בדידים או רציפים) ומשתנים איכוטיים (נקראים גם קטגוריאליים)

משתנים כמותיים- גיל, גובה, משכורת , מהירות

משתנים איכוטיים-מין , שייכות לקבוצה (A,B או C) , אבחן רפואי (סובל ממחלת, לא סובל ממחלת)

למידה מונחתית (Supervised Learning)

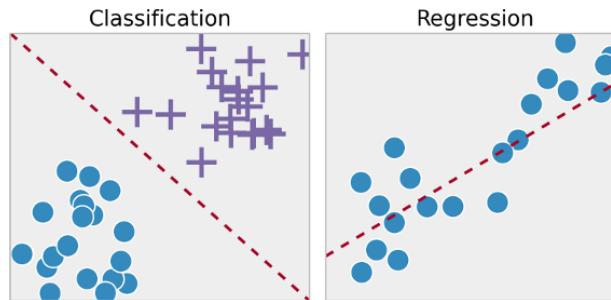


Regression VS Classification

אנו מסוגים בעיות כבויות רגסיה ואילו בעיות אינטיריות כבויות קלסיפיקציה (סיווג).

לעתים ישן אפשרות לייצג בעיות במספר צורות כאשר אנו מתאימים את המודל לצורך שלנו.

בשים לב: פרמטרי המודל X_1, X_2, \dots, X_p אינם מוכרים להיות מסווג חיזוי אותו אנו מבצעים וניתנים לקידוד בהתאם.



למידה מונחתית (Supervised Learning)



Parametric vs Non-parametric Methods

כשאנו מנסים למדוד את $(x) \hat{f}$ ישן שני דרכים בהן אנו יכולים להגדיר את הבעיה: פרמטרית / א-פרמטרית.

- מודול פרמטרי:

זהו אותו מודול בו השתמשנו בשקפים הקודמים : ייצוג של $(x) \hat{f}$ כמשווהה ליניארית של כל הפרמטרים לדוג'ן:

$$\hat{f}(x) = b_0 + b_1 x_1 + b_2 x_2$$

הדרך להתאים את הפרמטרים של המודל היא (כפי שראינו בדוגמה) שימוש ב"מדדית המרחק" בין המודל שלנו והתחזיות שלו לבין התוצאות האמתיות.

מהו לדעתכם היתרון והחיסרונו בשיטה זו?

למידה מונחתית (Supervised Learning)



Parametric vs Non-parametric Methods

יתרון: תהליכי האימון ושיעור הפונקציה הוא משימה פשוטה קלה יחסית שאיננה דורשת עבודה חכמתית רבה.

חיסרון: העולם (בד"כ) אינו מתנהג בצורה לינארית ולכן, ברוב המקרים מודל לינארי רגיל ייצג בצורה חלשה ולא מדויקת את הבעה.

על מנת להתמודד עם החיסרון נוכל לעשות שני דברים:

א. הגדרת מודל מורכב יותר בעל מספר רב של פרמטרים שייצג בצורה יותר טובה את הבעה (חישבו מה הבעה?)

ב. מעבר לשיטה א-פרמטרית

למידה מונחתית (Supervised Learning)



Parametric vs Non-parametric Methods

מודול א-פרמטרי:

בניגוד למודל הפרמטרי שבוצע הנחות על צורת הפונקציה, המודל הא-פרמטרי לומד את הפונקציה ללא הנחות קודומות ומנסה למצוא פונקציה קרובה ככל האפשר כך שתחזה את הדגימות.

גם בשיטה זו כמובן ישנו יתרון וחיסרון:

יתרון: הפונקציה מתארת בצורה יותר טובה את המודל.

חיסרון: נדרש מספר רב מאוד של דוגימות על מנת לקבל קירוב טוב לפונקציה.

למידה מונחת (Supervised Learning)



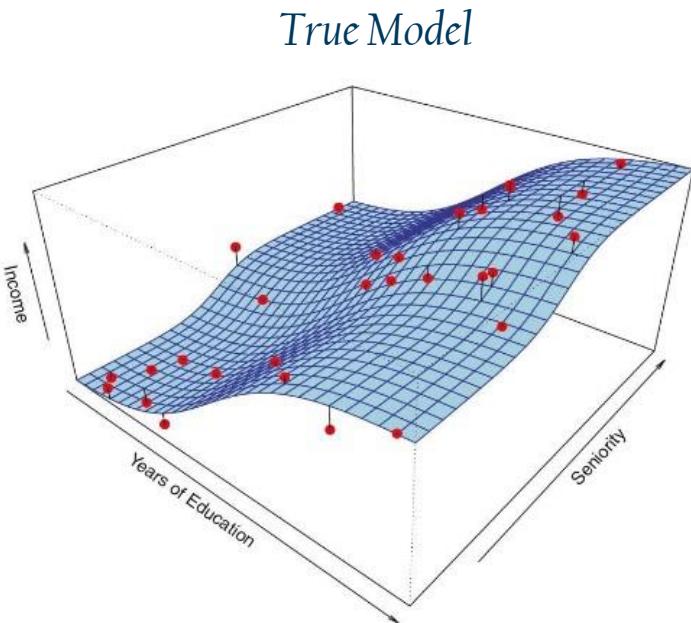
Parametric vs Non-parametric Methods

על מנת להמחיש את ההבדל בין הגישות השונות בעבר
לדוגמא.

נניח, שיש לנו עבור כל עובד את הנתונים הבאים:

- הכנסה החודשית
 - הותק
 - שנות לימוד.

אנו מעוניינים לבנות מודל כך שיתאר את הכניסה כפונקציה של הותק ושותות הלימוד



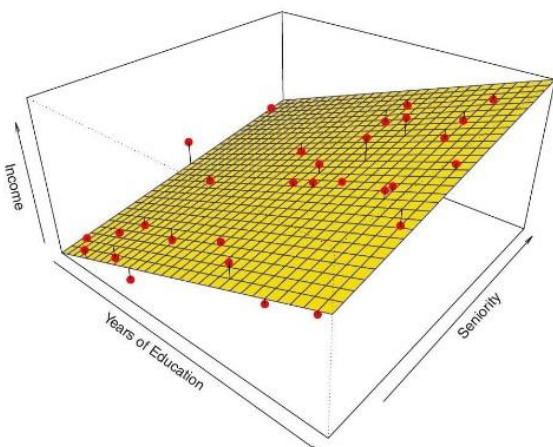
למידה מונחתית (Supervised Learning)



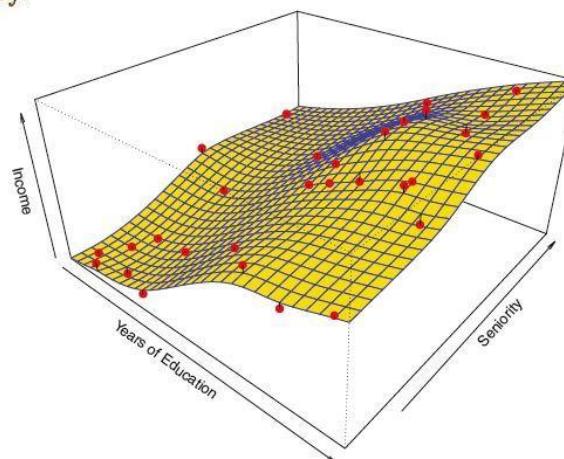
Parametric vs Non-parametric Methods

Linear Model

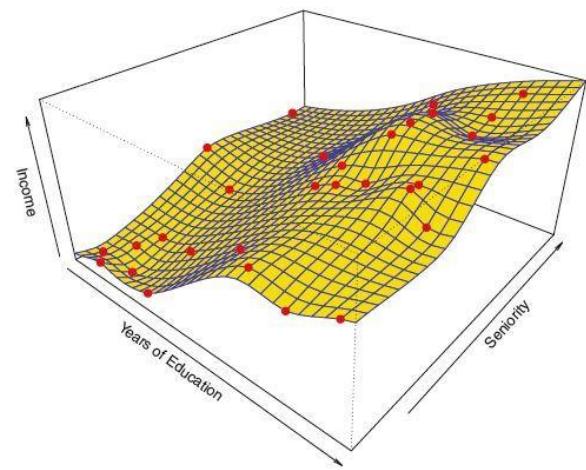
$\text{income} \approx \beta_0 + \beta_1 \times \text{education} + \beta_2 \times \text{seniority}$.



Non-Linear V₁



Non-Linear V₂



למידה מונחתית (Supervised Learning)



Parametric vs Non-parametric Methods

ניתן לשים לב כי המודל הימני בשקף הקודם מתאים בצורה מושלמת לכל הדגימות, האם זהו דבר טוב?

בוחלט לא!

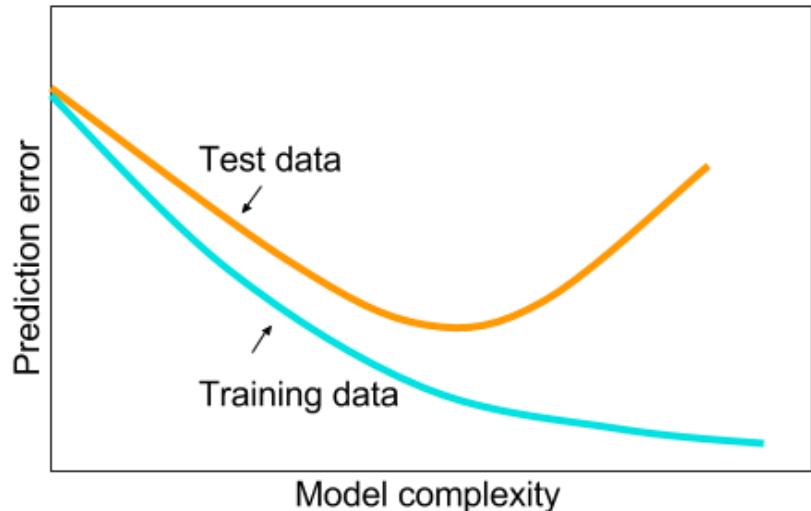
בעיה זו ידועה יותר בשם – "התאמת יתר" של המודל לנוטוני האימון.

ניתן לראות זאת ע"י האיור הבא:

נשים לב שישנו שלב שהשגיאה על מדגם האימון יורדת אך רמת השגיאה על מדגם המבחן עולה

המסקנה

צריך למצוא איזון בין דיוק המודל לבין יכולת ההכללה שלו למקדים חדשים



למידה מונחתית (Supervised Learning)



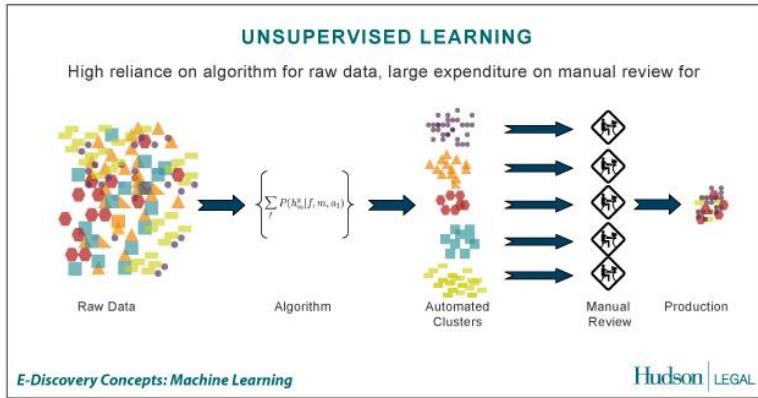
שאלות פתוחות:

בעולם האמיתי המידע הרבה יותר מורכב ורועש ובעל מאות פרמטרים ולעתים נתקל בבעיות הבאות:



- כיצד נתמודד עם ערכים חסרים?
- אילו פרמטרים נבחר? האם ניתן ליצור פרמטרים חדשים ויתר מייצגים?
- כיצד נעריך נכון את השגיאה?
- איך נדע שהמודל שלנו יחזה נכון גם במקרים שהוא עוד לא ראה?

למידה לא-מנוחית (Unsupervised Learning)



למידה לא-מנוחית היא למידה בה המידע שיש לנו (בניגוד ללמידה מונוחית) מרכיב מחלק הפרמטרים בלבד: x .

בסוג למידה זה, המטרה איננה לחזות ערך/תיוג אלא לנסות למצוא מבנה וקשרים בתוך המידע עצמו.

לדוגמא : מציאת סוגים שונים בחברה על סמך הפרמטרים שלהם.

מטרה נוספת אנו מתייחסים היא הורדת מידע – מציאת ייצוג דחוס וקומפקטי יותר של הדגימה המקורי תוך שימירה (כל שniton) על ייצוג נכון של הדגימה במרחב.

למידה לא-מנוחית (Unsupervised Learning)



דוגמה

נניח ואנו מנהלים רשת גדולה של פיצריות.

לאחרונה, ערכנו איסוף של נתונים הלקוחות שלנו והמיוקמים מהם מתכבותות ההזדמנויות שלהם, והגענו למסקנה שאנו צריכים מעוניינים לפתח 3 סניפים חדשים באזורי.

המטרה:

מיקום הסניפים בצורה המיטבית כך שנוכל לחלק את הפיציות ביעילות מרבית.



למידה לא-מנוחית (Unsupervised Learning)



דוגמה

כיצד נוכל למקם את הסניפים בצורה הכי טובה?

נשתמש באגוריתם K-Means:

זהו אגוריתם איטרטיבי, כך שבכל שלב מחשבים
מרכזואידים (מרכזי כובד) לכל הנקודות שבאותו מחלקה
(במקרה שלנו פיצריה).



בכל פעם, בוחנים לאיזה מרכזoid כל נקודה קרובה יותר
ומשייכים אותה אליו. לאחר הסידור מחדש מחשבים שוב
מרכזואידים וכך הלאה עד להתכנסות.

למידה לא-מנוחית (Unsupervised Learning)



דוגמא

שלב ראשון: אתחול

בשלב הראשון נאותחל את מיקומי הפיצריות (מרכזואידים) בצורה שרירותית. כאשר כל עיגול צבעוני מייצג פיצריה אחת.

כיצד נדע מהי איקות החלוקת שלנו?



למידה לא-מנוחית (Unsupervised Learning)



דוגמא

שלב שני: שירולוקוחות



כעת, נמדדוד לכל ליקוח את מרחקו מכל הפייצריות ונבחר את השירולוקו שלו להיות הפיצריה הקרובה ביותר אליו.

נשים לב, בשלב זה אנו רק משייכים את הליקוחות לפייצריות לפי האתחול הראשוני.

אתחלולים שונים יתכנסו לתוצאות שונות ולכן חשוב לבחור בצורה זיהירה וחכמה את מרכז הלקוחיים הראשוניים

למידה לא-מנוחית (Unsupervised Learning)

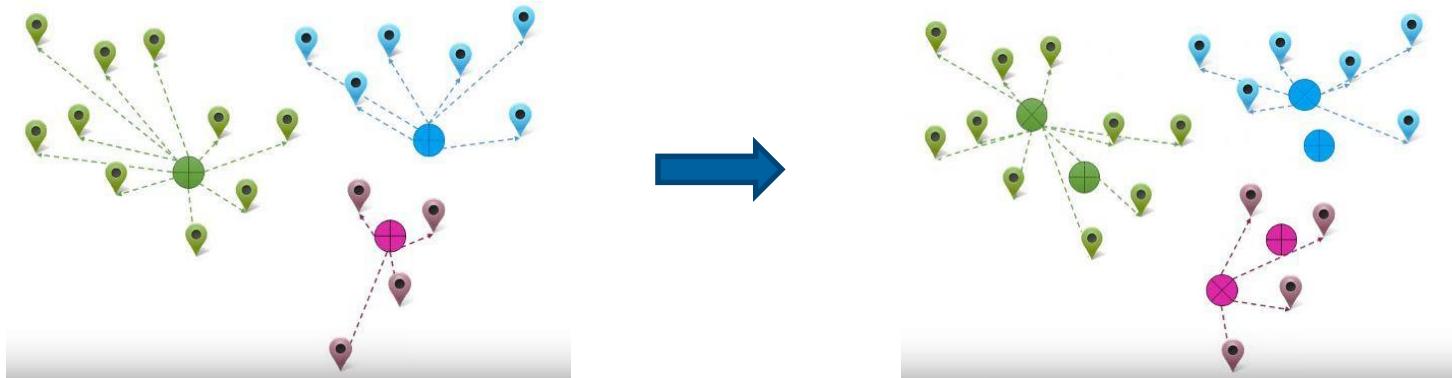


דוגמא

שלב שלישי: חישוב צנטרואידים חדשים:

לאחר שייכנו כל לוקו לפייריה אחת, נחשב עבור כל פייריה את מרכז הקובד (צנטרואיד) של הלקחות שלה ונמוקם את הפייריה מחדש שם.

הчисוב הוא בעצם מציאת נקודת המצע היחסית לכל הנקודות באותה הקבוצה.



למידה לא-מנוחית (Unsupervised Learning)



דוגמה

שלב רביעי - חלוקה מחדש:

כעת, קיבלנו מיקומיים חדשים לפיצריות, ונוכל לבצע שוב את שלב החלוקה. נעבור על כל לקוחות ונסיר אותו לפיצריה הקרובה אליו. נשים לב שהSievor השתנה.



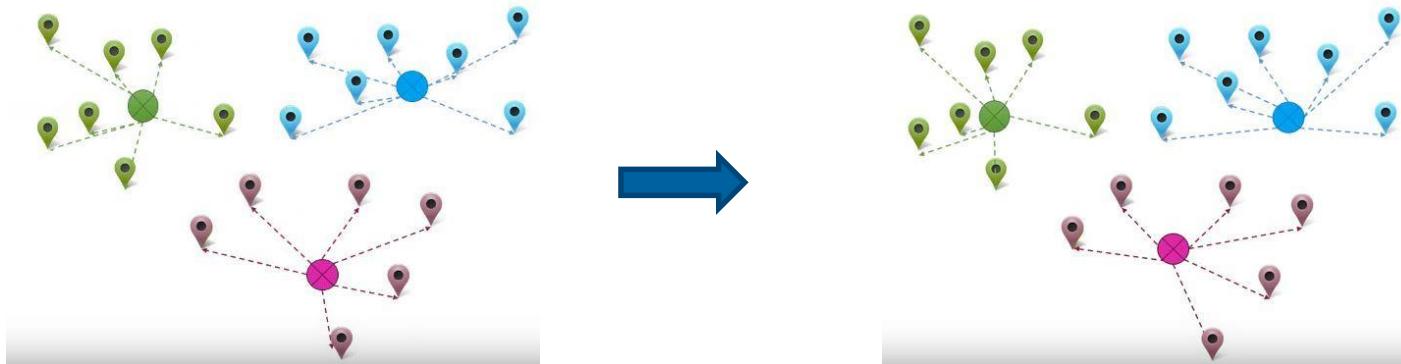
למידה לא-מנוחית (Unsupervised Learning)



דוגמא

שלב חמישי - מיקום חדש:

בדומה לשלב השלישי, נחשב עבור כל פיצרייה מיקום חדש בהתאם לצנטרואיד הלוקוחות שלה



למידה לא-מנוחית (Unsupervised Learning)



דוגמה

שלב שישי- ניהול מחדש והתקנות

הגענו לשלב בו אין תוצאות**לקוחות** בין הפיצריות, מצב זה מוגדר כהתכנסות. וקיבלונו את המיקומים הסופיים של הפיצריות



למידה לא-מנוחית (Unsupervised Learning)



דוגמאות-שאלות פתוחות

בדומה ללמידה מונוחית גם כאן מספר שאלות שאנו צריכים לשאול כשאנו ניגשים למודלים מסווג זה:

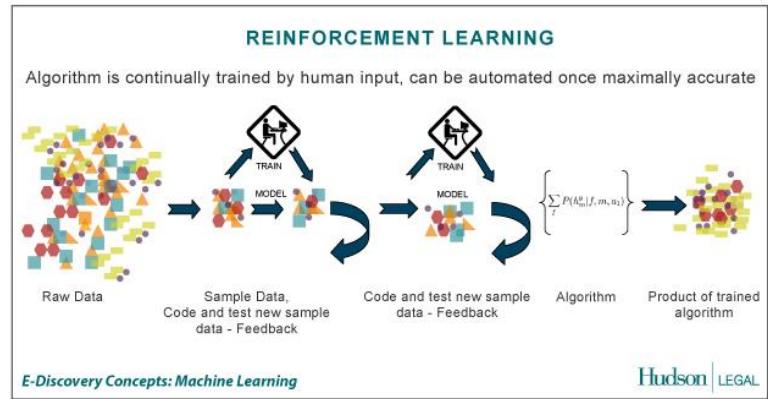


- כיצד נבצע אתחול ריאשוני מוצלח?
- לכמה clusters אנו מעוניינים לחלק את המרחב? איך נשווה בין החלוקות ?
- כיצד נתמודד עם דוגמאות קייזן?
- האם כל הדוגמאות בעלות משקל זהה?

למידה מחיזוקים (Reinforcement Learning)



למידה מחיזוקים היא למידה בה המידע שיש לנו הוא על העולם/סביבה ו-סט הפעולות האפשריות לביצוע.



בסוג למידה זה, המטרה היא לימוד הסוכן (רובוט/רכיב תוכנה) אילו פעולה כדאי לו לבצע באילו מצבים וזאת על מנת להשיג תגמול מקסימלי.

סוג למידה זה הוא ייחודי מורכב וכולל המון תת-אפשרויות בקשר לעולם הנלמד:

- סוכן יחיד vs סוכנים רבים
- עולם גלוי/עולם נסתר
- עולם דטרמיניסטי/עולם סטוכסטי



از מה ראיינו היום?

- למידה חישובית – למה דואק אעכשווים?
- הגדרה: מהי למידה חישובית
- שימושיים נפוצים ומעשיים
- סוגים הלמידה השונים ושימושיהם
- דוגמאות מנהחות
- שאלות פתוחות

תודה על ההגשה